

Professor: Munif Gebara

Integrantes: Carlos Eduardo Souza Favarão 23034356-2

Heloísa Tognolli Scarante 23211463-2

Contextualização

Os jogos competitivos online geram uma grande quantidade de dados sobre o desempenho dos jogadores. Em jogos como Valorant, informações como eliminações, mortes, assistências, dano causado, dano recebido, headshots e ranking competitivo permitem identificar padrões de comportamento e diferentes estilos de jogo. A análise desses dados por meio de técnicas de Inteligência Artificial oferece uma oportunidade de segmentar automaticamente os perfis de jogadores, gerando insights úteis para equipes, coaches e plataformas de esportes eletrônicos.

Problematização e Objetivo

O objetivo do trabalho é identificar perfis distintos de jogadores com base em suas estatísticas de desempenho, utilizando técnicas de agrupamento e classificação. A hipótese central é que as métricas coletadas permitem separar automaticamente jogadores em grupos coesos — como perfis mais competitivos, casuais ou intermediários — e que esses grupos podem ser reproduzidos por um classificador supervisionado com alta acurácia.

Dataset

Foi utilizado o Valorant Dataset V3, disponível na plataforma Kaggle (notnguyen/valorant-dataset-v3). O dataset contém estatísticas de desempenho de múltiplos jogadores coletadas ao longo de diversas partidas competitivas.

Principais Atributos

Atributo	Descrição
kills	Total de eliminações
deaths	Total de mortes
assists	Total de assistências
damage	Dano total causado
damage_received	Dano total recebido

headshots	Total de headshots
traded	Mortes trocadas com aliados
matches	Número de partidas jogadas
tier	Rank competitivo do jogador

Tratamento dos Dados

O pipeline de preparação dos dados seguiu as etapas abaixo:

- Remoção da coluna player (identificador sem valor preditivo para o modelo).
- Conversão das colunas numéricas em formato de texto com separadores de milhar (ex: "1,234" → 1234).
- Eliminação de linhas com valores nulos após a conversão.
- Label Encoding da coluna tier, transformando os ranks categóricos em valores numéricos ordinais.
- Substituição de zeros por 1 nas colunas kills, deaths e matches, evitando divisão por zero

Foram criados novos atributos derivados das estatísticas originais:

Atributo	Fórmula	Descrição
kd_ratio	kills / deaths	Eficiência em eliminações
headshot_ratio	headshots / kills	Precisão nos abates
damage_per_match	damage / matches	Produção ofensiva média por partida
assist_per_match	assists / matches	Suporte médio por partida
traded_ratio	traded / matches	Taxa de mortes trocadas por partida

Normalização

Todos os atributos foram padronizados com StandardScaler (média 0, desvio padrão 1). Essa etapa é obrigatória para algoritmos baseados em distância como K-Means e KNN, pois garante que nenhuma variável com escala maior domine artificialmente o cálculo de proximidade.

Divisão Treino/Teste

Para os modelos supervisionados, a base foi dividida em 80% treino e 20% teste, com stratify=y para garantir proporção igual de classes em ambos os conjuntos.

Métodos de IA utilizados

K-Means (Aprendizado Não Supervisionado)

O K-Means é um algoritmo de clusterização que agrupa os dados sem utilizar rótulos previamente definidos. O algoritmo posiciona K centroides no espaço de features e, iterativamente, atribui cada ponto ao centroide mais próximo e recalcula a posição dos centroides como a média dos pontos de cada grupo, repetindo até convergir.

Para determinar o número ideal de clusters, foram utilizados dois métodos:

- **Método do Cotovelo:** plota a inércia para K de 1 a 10. O ponto de inflexão indica onde aumentar K deixa de trazer ganho expressivo.
- **Silhouette Score:** mede a coesão interna e a separação entre clusters. Varia de -1 a 1; o K com maior score foi selecionado automaticamente.

O K-Means identificou 3 clusters, interpretados como: Veteranos (alta KD ratio e dano), Competitivos (desempenho intermediário consistente) e Casuais (menor volume de partidas e métricas mais baixas).

K-Nearest Neighbors (KNN) – Aprendizado Supervisionado

Após a clusterização, os rótulos gerados pelo K-Means foram utilizados como variável alvo para o treinamento do KNN. O algoritmo classifica um novo ponto com base nos K vizinhos mais próximos no espaço de features: a classe mais frequente entre esses vizinhos é atribuída ao ponto. O KNN não constrói um modelo explícito — ele memoriza os dados de treino e realiza o cálculo de distâncias no momento da predição. O valor de K foi testado de 1 a 20 vizinhos, medindo a acurácia em cada caso. O K com maior acurácia foi selecionado automaticamente. A validação cruzada com 5 folds foi aplicada para confirmar a robustez do modelo.

Árvore de Decisão – Comparação

A Árvore de Decisão foi utilizada como modelo comparativo ao KNN. O algoritmo aprende regras hierárquicas dividindo os dados recursivamente com base na feature e no limiar que melhor separa as classes (critério Gini). O parâmetro `max_depth=5` foi definido para evitar overfitting. Uma vantagem importante da Árvore de Decisão é a interpretabilidade: ela gera um gráfico de importância das variáveis, revelando quais features mais influenciaram as decisões do modelo.

Avaliação dos Modelos




K-Means





- Método do Cotovelo — identificação visual do número ideal de clusters
- Silhouette Score — medida quantitativa da qualidade dos agrupamentos.
- Visualização PCA — redução para 2 componentes principais para plotagem dos clusters em 2D.

KNN e Árvore de Decisão


Ambos os modelos foram avaliados com as seguintes métricas:

Métrica	O que mede
Acurácia	Proporção de classificações corretas sobre o total
Precisão	Dos classificados como X, quantos realmente são X
Recall (Revocação)	Dos que realmente são X, quantos foram classificados corretamente
F1-Score	Média harmônica entre Precisão e Recall
Matriz de Confusão	Distribuição de acertos e erros por classe






Importância das Variáveis (Decision Tree)



Fronteiras de Decisão da Árvore de Decisão



Comparação dos Resultados

Critério	KNN	Árvore
Interpretabilidade	Baixa	Alta (regras visíveis)
Velocidade de predição	Lenta (calcula distâncias)	Rápida
Sensível à normalização	Sim (obrigatório)	Não
Importância de features	Não disponível	Disponível
Risco de overfitting	Controlado pelo K	Controlado pelo max_depth
Acurácia	0.9759	0.9425

Conclusão

O projeto demonstrou que é possível identificar perfis distintos de jogadores de Valorant de forma automática utilizando técnicas de Inteligência Artificial não supervisionada e supervisionada de maneira complementar. O algoritmo K-Means identificou três grupos coesos de jogadores com características estatísticas bem diferenciadas. A técnica de PCA permitiu visualizar graficamente a separação entre esses grupos no espaço bidimensional. O KNN e a Árvore de Decisão, treinados sobre os rótulos gerados pelo K-Means, demonstraram alta capacidade de reproduzir os padrões identificados na clusterização. A validação cruzada confirmou a consistência dos modelos, indicando baixo risco de overfitting.

A Árvore de Decisão oferece vantagem interpretativa ao revelar quais features são mais relevantes para a classificação dos perfis. O KNN, por sua vez, é mais simples de implementar e robusto para datasets de tamanho moderado. Como trabalhos futuros, sugere-se explorar algoritmos como Random Forest ou Gradient Boosting para comparação adicional, bem como aumentar a base de dados e testar diferentes configurações de feature engineering.